Rapport De Data Competition

Introduction :

La détection des gaz toxiques est un enjeu crucial en matière de sécurité, notamment dans les environnements industriels. L'utilisation de capteurs couplés à des modèles de machine learning permet d'automatiser cette tâche et d'améliorer la fiabilité des systèmes de détection.

Pseudo : Mozo
Score Public : 0.1392
Score Privé : 0.1386
Rang : 3/49

Auteur : ASGHAR ALI Thomas
https://github.com/Mozo953/Data_comp.git
E4 DSIA

21 Avril 2026

Introduction :
I) Description du problème
II) Exploration des données et EDA :
Différence de distributions :
III) Modèle et Algorithme :
IV) Observation & Test :
Conclusion
Références bibliographiques :
Annexes :
Annexe 1 :
Annexe 2 :
Annexe 3 :
Annexe 4 :

I) Description du problème

Dans cette data compétition, l'objectif est de prédire, à partir de mesures issues de capteurs ainsi que de variables environnementales, 23 variables cibles continues comprises entre 0 et 1. Ces variables représentent le niveau de présence ou d'activation de différents gaz. Le problème est ainsi modélisé comme une tâche de régression multi-sorties. L'évaluation repose sur une RMSE pondérée, qui pénalise davantage les erreurs sur les valeurs élevées afin de privilégier la détection des situations critiques. Les performances du modèle sont ainsi mesurées à l'aide de cette erreur, calculée sur l'ensemble des variables cibles.

$$\text{Score} = \sqrt{\frac{1}{N}\sum_{n=1}^{N}\frac{1}{23}\sum_{i=1}^{23} f_{n,i}(c_{n,i} - \hat{c}_{n,i})^2}$$

avec $f = \begin{cases} 1 & \text{si } c_i < 0.5 \\ 1.2 & \text{si } c_i \geq 0.5 \end{cases}$ où c_i est la vraie valeur (ground truth) et $\hat{c}_i$ la valeur prédite.

II) Exploration des données et EDA :

L'ensemble de données se compose de données d'apprentissage, de cibles associées et d'un ensemble de test distinct. L'analyse exploratoire a été réalisée à l'aide du framework *ydata_profiling*, offrant une vision globale des distributions, corrélations et anomalies présentes dans les données. Les variables d'entrée présentent une forte hétérogénéité statistique, reflétant la diversité des capteurs. Cette variabilité se traduit par plusieurs comportements caractéristiques mis en évidence lors de l'EDA comme :

- Les capteurs **M4–M7** et **M12–M15** présentent des distributions fortement asymétriques, caractérisées par des queues longues et la présence d'outliers significatifs. Cela suggère une sensibilité élevée à certaines conditions extrêmes.
- Des **corrélations structurées** apparaissent : fortes au sein des groupes (redondance), et négatives entre groupes, traduisant des comportements opposés exploitables par le modèle.
- Les variables **S2** et **S3** ont un pouvoir informatif limité : **S2** est très concentrée autour de 1 (forte asymétrie), tandis que **S3** présente une faible variance.

Globalement, les données d'entrée sont marquées par des **distributions non gaussiennes**, une **présence importante d'outliers** et des **corrélations structurées**, ce qui justifie l'utilisation de modèles robustes aux transformations non linéaires et d'un pré-processing. L'analyse des *variables cibles* met en évidence plusieurs propriétés structurantes du problème :

- Les cibles sont **fortement déséquilibrées**, avec une proportion très élevée de valeurs nulles.
- La majorité des variables sont sparsifiées(80 % à 99 % de zéros), ce qui reflète la rareté de certains gaz dans les observations.
- Certaines cibles (**c03, c04, c22**) concentrent l'information, tandis que **c15** est constante et non exploitable.
- Des **groupes de cibles parfaitement corrélées** apparaissent, tels que *(c03, c04, c22)*, *(c05, c21)* et *(c02, c07, c20)*, suggérant une redondance et la possible existence de facteurs latents communs.

Ces observations mettent en évidence un problème de **régression multi-sorties fortement déséquilibré et redondant**, où certaines cibles dominent la structure de l'information. Elles justifient l'utilisation de stratégies de réduction de dimension des cibles, de pondération adaptée et de modèles capables d'exploiter les corrélations entre sorties afin d'améliorer la robustesse et la généralisation.

Différence de distributions :

L'analyse exploratoire des données (EDA), avec notamment le tracé des distributions train et test en fonction de la variable **Humidity**, met en évidence un décalage significatif entre les deux set de données. Cette différence de distribution suggère la présence d'un **covariate shift**, indiquant que les conditions environnementales ne sont pas représentées de manière homogène entre train et test.

Afin de confirmer ce phénomène, une validation adversariale, qui est un modèle de classification binaire train/test, a été réalisée en entraînant un modèle **XGBoost**, choisi pour sa capacité à capturer des relations non linéaires complexes. Ce choix est pertinent dans ce contexte, car une simple régression logistique ou un modèle plus léger pourrait sous-estimer les différences entre les distributions. Les résultats montrent que le modèle est capable de **séparer presque parfaitement les données de train et de test (AUC = 0.98)**, ce qui constitue une preuve claire d'un décalage de distribution entre X_{train} et X_{test}.

L'analyse des variables les plus discriminantes pour la séparation train/test met clairement en évidence que *Humidity* domine largement, avec une importance nettement supérieure aux autres variables (≈ 0.24 contre < 0.09 pour M13, S1, S3). Cela indique que le modèle s'appuie principalement sur cette variable pour distinguer les deux distributions, plutôt que de capturer des relations pertinentes avec le phénomène cible, ce qui introduit un risque d'overfitting et de mauvaise généralisation.

Dans ce contexte, le covariate shift est majoritairement porté par *Humidity*, les autres variables ayant un rôle secondaire. La différence entre train et test est donc fortement structurée par cette variable, ce qui peut conduire le modèle à apprendre un signal spécifique au jeu d'entraînement. Lorsque la distribution de *Humidity* évolue en test, ce signal devient non pertinent, entraînant une dégradation des performances et de la capacité de généralisation.

III) Modèle et Algorithme :

Mon *best model* est conçu notamment pour limiter l'impact du covariate shift, en particulier celui lié à *Humidity*.

Le prétraitement consiste en un **clipping entre les quantiles 1 % et 99 %** pour réduire l'influence des valeurs extrêmes et stabiliser l'apprentissage. La variable Humidity, identifiée comme principale source de décalage de distribution, est supprimée afin d'éviter un apprentissage biaisé. Cette suppression améliore les performances (14,10 → 13,92).

Le modèle repose ensuite sur un **blending de deux ExtraTrees** (modèles non paramétriques robustes aux distributions non gaussiennes et aux outliers) utilisant des stratégies de feature engineering complémentaires. Le modèle *et_rowagg_bs* exploite des variables agrégées (≈26 features) pour capturer des tendances globales et lisser le bruit. Le modèle *et_allpool* utilise un ensemble plus riche (≈130 variables) incluant transformations et interactions pour modéliser des relations plus complexes. L'objectif est de réduire la variance globale en combinant des modèles aux erreurs faiblement corrélées. Une analyse de type SHAP met en évidence que le feature engineering joue un rôle déterminant dans les performances du modèle, certaines variables construites ayant un impact significatif sur les prédictions. Cette analyse est détaillée en Annexe 1.

Les deux modèles sont entraînés avec la **MSE**, car c'est le critère optimisé nativement par les algorithmes d'arbres dans **scikit-learn**. Il n'est pas possible d'entraîner directement ces modèles avec une autre métrique comme la RMSE pondérée. Leurs hyperparamètres sont volontairement différenciés : *et_allpool* est plus contraint (≈ `300 arbres, max_depth = 24, sans bootstrap`) pour limiter l'overfitting, tandis que *et_rowagg_bs* est plus flexible (≈ `500 arbres, max_depth = 18, bootstrap activé`) pour favoriser la diversité. Les hyperparamètres sont optimisés avec **Optuna**, qui explore automatiquement différentes configurations via des méthodes d'**optimisation bayésienne**, en particulier les algorithmes de type **TPE (Tree-structured Parzen Estimator).**

Certaines cibles étant fortement corrélées, un **regroupement** est effectué afin de réduire la dimension du problème et éviter d'apprendre plusieurs fois la même information, ce qui limite la redondance et améliore la stabilité. Seul un sous-ensemble représentatif est prédit, les autres étant reconstruites à partir de celui-ci (le mapping de la prédiction des targets est disponible en annexe 2).

La combinaison des deux modèles repose sur un méta-learner optimisé indépendamment pour chaque cible, dans un espace de poids contraint au simplex de Dirichlet, imposant une combinaison convexe de coefficients

positifs dont la somme est égale à 1. La prédiction finale est ainsi une moyenne pondérée des sorties des deux modèles, garantissant une agrégation stable, interprétable et limitant les effets de sur-ajustement. Les poids sont appris en minimisant directement la RMSE pondérée, ce qui aligne explicitement le processus de blending avec la métrique d'évaluation. Pour chaque cible, le méta-learner adapte la contribution relative des deux ExtraTrees en fonction de leurs propriétés respectives, notamment leur capacité à gérer la sparsité, le bruit et les non-linéarités. Empiriquement, les résultats mettent en évidence une dominance du modèle et_allpool, tandis que et_rowagg_bs intervient principalement pour corriger des erreurs locales, ce qui confirme la complémentarité des deux approches.

L'évaluation repose sur une **validation croisée (CV = 3)** complétée par un **hold-out de 20 %**, permettant d'estimer à la fois la robustesse et la capacité de généralisation.

IV) Observation & Test :

Dans un premier temps, une stratégie de **post-processing avec shrinkage**, consistant à **ramener** les prédictions vers une **valeur moyenne** afin de limiter **les extrêmes**, a été introduite afin de limiter l'overfitting. En présence d'un **covariate shift**, cette approche s'est révélée inadaptée, car elle agit uniquement sur la complexité du modèle sans traiter le décalage de distribution entre les données d'entraînement et de test. En pratique, son retrait a permis un gain significatif sur le score, confirmant que la principale difficulté du problème réside davantage dans le shift de distribution que dans la capacité du modèle.

Dans un contexte de **covariate shift**, certaines régions des données deviennent plus difficiles à prédire en raison du décalage entre les distributions d'entraînement et de test. L'objectif est alors de mieux prendre en compte ces zones critiques en intégrant la difficulté locale et le déséquilibre train/test. Dans cette optique, une formulation continue a été proposée, inspirée des méthodes de *density ratio*, combinant plusieurs facteurs pour mieux représenter les zones difficiles (formule détaillée en annexe 4). Cependant, malgré sa cohérence théorique, elle n'a pas permis d'améliorer les performances en pratique.

Un modèle **ExtraTrees** sans feature engineering, entraîné uniquement sur les variables brutes, a également été testé. Bien que très performant sur le train, il présentait un **surapprentissage marqué** et une capacité limitée à bien généraliser. Initialement intégré au **meta-learner**, il accentuait l'écart entre train et validation et pénalisait les performances hors échantillon. Son retrait a permis d'améliorer la robustesse du modèle final, avec un score passant d'environ **0.1410 à 0.1391 (**sur le test public).

Enfin, des modèles comme **AdaBoost** et le **Gradient Boosting** ont été testés de manière ciblée sur certaines zones de la distribution, en particulier des **bins d'humidité où le modèle principal était en difficulté**. L'idée était d'exploiter ces modèles comme compléments, car des analyses préalables avaient montré une **faible corrélation de leurs erreurs** avec celles des ExtraTrees, suggérant un potentiel gain via spécialisation locale. Cependant, en pratique, cette approche n'a pas permis d'améliorer les performances. Malgré une faible corrélation des erreurs avec celles des ExtraTrees, ces modèles se sont révélés instables sur les sous-ensembles considérés, limitant leur contribution effective.

Conclusion

Ce projet a été particulièrement enrichissant, car il m'a permis de consolider les bases du machine learning tout en découvrant des notions plus avancées comme le covariate shift, la validation adversariale, le shrinkage ou encore les meta-learners. Il met en évidence que la performance d'un modèle ne repose pas uniquement sur son choix, mais aussi sur la compréhension fine des données et de leurs biais. Il m'a surtout appris l'importance d'analyser les décalages de distribution, de limiter l'overfitting et d'adapter les méthodes aux contraintes réelles du problème. Le modèle final atteint un score de 0.1392 (public) et 0.1386 (privé), ce qui confirme la pertinence de l'approche mise en place face au covariate shift.

Une piste d'amélioration serait désormais de **mieux comprendre le contexte physique des variables d'entrée** et d'**analyser plus finement leur poids réel dans les modèles**, afin d'interpréter davantage les prédictions et de guider plus intelligemment le feature engineering.

Références bibliographiques :

https://www.columbia.edu/~yt2661/STL/slides/Lecture-3.pdf *[cours sur la covariate shift]*

https://www.stat.berkeley.edu/~jsteinhardt/stat260/notes/lect20.pdf *[cours covariate shift]*

https://www.jmlr.org/papers/volume8/sugiyama07a/sugiyama07a.pdf *[article scientifique sur covariate shift]*

https://pypi.org/project/ydata-profiling/ *[framework pour l'EDA]*

https://towardsdatascience.com/organizing-code-experiments-and-research-for-kaggle-competitions/ [*organisation de code / architecture]*

https://optuna.org/ *[framework d'optimisation des paramètres]*

Annexes :

Annexe 1 :

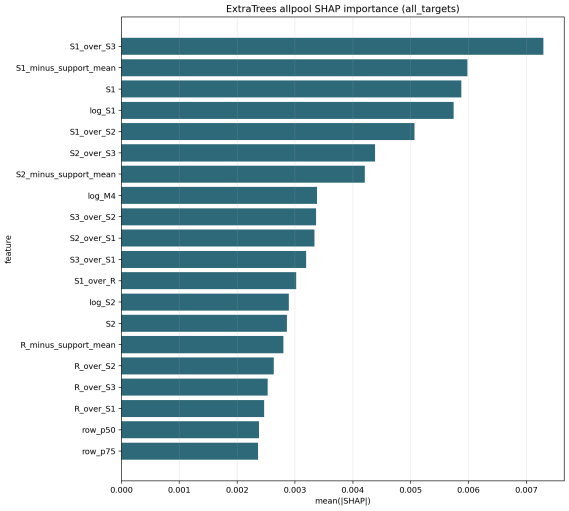

Analyse des features importance via SHAP sur et_allpool

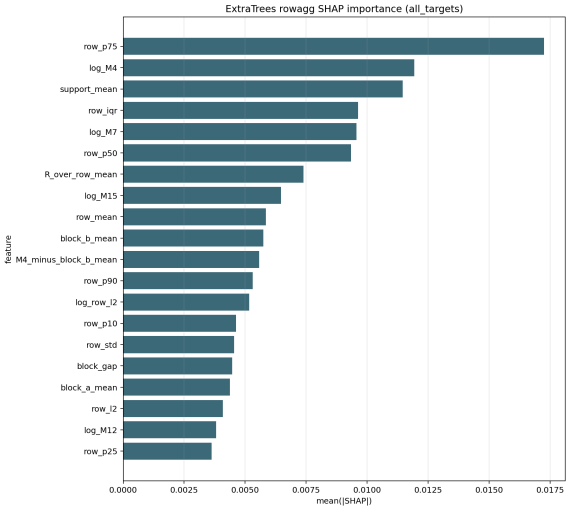

Analyse des features importance via SHAP sur et_rowagg_bs

Annexe 2 :

$$\begin{cases} c03 \longrightarrow c04,\ c22 \\ c05 \longrightarrow c06,\ c21 \\ c02 \longrightarrow c07,\ c20 \end{cases}$$

mapping des targets

Annexe 3 :

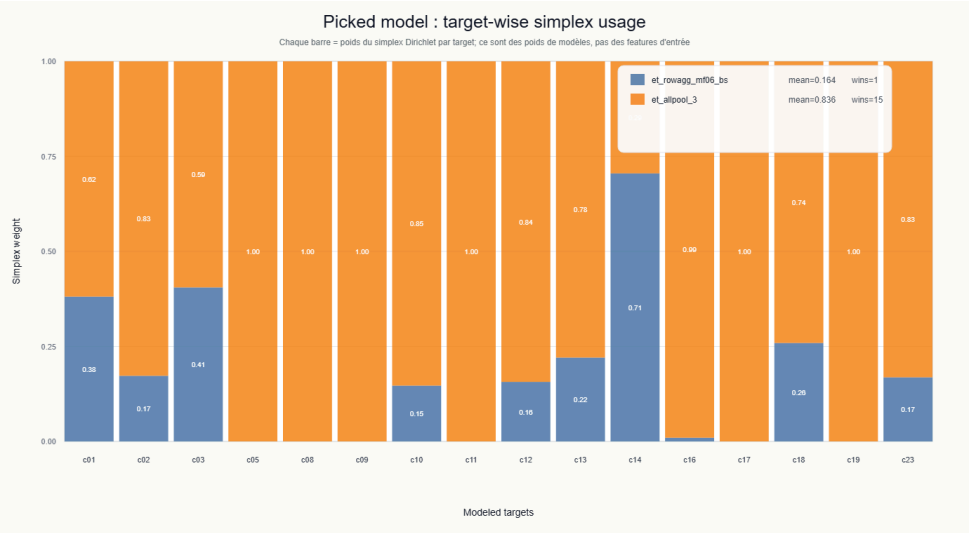

Répartition des poids du modèle via le simplex de Dirichlet

Annexe 4 :

$$w_j = clip(1 + \alpha \cdot D(b_j) + \beta \cdot R(b_j) + \gamma \cdot e_j)$$

Cette formulation combine trois sources de difficulté : la complexité locale via $D(b_j)$, le décalage de distribution via $R(b_j)$, et l'erreur propre à chaque observation et e_j. Elle permet ainsi d'identifier les zones à la fois difficiles et sous-représentées dans les données. L'objectif est de renforcer le poids de ces observations critiques lors de l'apprentissage afin d'améliorer la généralisation.